Observatorio ciudadano de contratación pública

Proyecto de portafolio: asistente RAG en la nube y modelo de Machine Learning sobre datos abiertos de SECOP II

Proyecto personal para blog y LinkedIn | Fuente de datos: SECOP II (datos abiertos) | Versión 2.3 | 28 de octubre de 2026

1. Descripción del caso

La contratación pública es un canal central del gasto del Estado y su información se publica como datos abiertos. El volumen del conjunto de datos (millones de registros y decenas de columnas) y la necesidad de conocer el marco legal dificultan que ciudadanos, veedurías, periodistas y equipos de control interno respondan preguntas básicas o identifiquen contratos que merecen una revisión más atenta.

El proyecto construye un **Observatorio ciudadano de contratación pública** sobre SECOP II, con dos componentes que comparten la misma fuente y que se publican como piezas de portafolio:

Componente	Qué resuelve
A. Asistente en la nube (RAG)	Responde en lenguaje natural con cifras (base SQL) y con normativa (base vectorial en la nube), citando sus fuentes.
B. Machine Learning clásico con Streamlit	Estima la probabilidad de que un contrato requiera prórroga de plazo y la presenta en una aplicación para explorar y consultar.

Usuario	Necesidad real	Uso del sistema
Veedurías ciudadanas	Saber cuánto, con quién y bajo qué modalidad contrata una entidad	Preguntas al asistente y filtros de exploración
Periodistas de datos	Contrastar cifras con lo que dice la ley	Consultas mixtas (SQL y normativa) con citas verificables
Control interno de entidades	Priorizar qué contratos revisar primero	Estimación de riesgo de prórroga y su explicación
Reclutadores y colegas del sector	Evaluar criterio técnico y capacidad de comunicación	Repositorio, demo, artículo y publicación

> **Uso responsable.** Los resultados describen patrones estadísticos y no constituyen evidencia de irregularidades. Toda alerta debe verificarse en el proceso original, disponible en el campo `urlproceso` del dataset.

2. Objetivos del proyecto de portafolio

Objetivo	Cómo se evidencia
Demostrar una arquitectura de datos híbrida en la nube (SQL y base vectorial)	Diagrama, repositorio y demo funcional
Demostrar Machine Learning clásico bien hecho: sin fuga de información, validación temporal y métricas honestas	Notebook, tabla de métricas y aplicación
Comunicar resultados y límites con claridad	Artículo de blog y publicación en LinkedIn
Entregar algo que otras personas puedan ejecutar	README, requirements.txt, datos reproducibles y demo pública

Qué lo distingue de un tutorial: usa datos reales con actualización diaria, normativa real, una evaluación con preguntas de respuesta verificable y una sección explícita de uso responsable.

3. Fuentes de datos públicas y condiciones de uso

Fuente	Contenido	Observaciones
SECOP II – Contratos Electrónicos (Colombia Compra Eficiente, datos.gov.co)	Aprox. 4.775.550 contratos publicados desde 2013 hasta el 31 de agosto de 2025; 87 columnas; llave única `id_contrato`; actualización diaria.	Puede tener campos nulos o inconsistentes y no incluye los documentos adjuntos de los contratos.
Diccionario de datos y ficha técnica – Registros administrativos (versión 1.0, agosto de 2025)	Descripción de cada columna, cobertura, frecuencia de actualización y marco normativo.	Base del diccionario de columnas del proyecto y de la cita del dataset.
Normativa de contratación	Ley 80 de 1993, Ley 1150 de 2007 y Decreto 1082 de 2015 (marco citado en el diccionario). Opcional: Ley 1712 de 2014 (transparencia).	Obtener los textos de fuentes oficiales y convertirlos a Markdown. El decreto es extenso: usar solo el título de contratación estatal.
Manual de datos abiertos del SECOP (Colombia Compra Eficiente)	Guía de uso de los datos abiertos del SECOP.	Documento complementario para el corpus.

Alcance y tratamiento de los datos

- **Subconjunto:** trabajar con un departamento y uno o dos años (entre 20.000 y 100.000 contratos), no con el conjunto completo.
- **Columnas sugeridas (unas 15):** `id_contrato`, `nombre_entidad`, `departamento`, `ciudad`, `sector`, `estado_contrato`, `tipo_de_contrato`, `modalidad_de_contratacion`, `fecha_de_firma`, `valor_del_contrato`, `proveedor_adjudicado`, `descripcion_del_proceso`, `objeto_del_contrato`, `urlproceso`.
- **Privacidad:** excluir nombres, documentos y domicilios de representantes legales, supervisores y ordenadores del gasto, así como los datos bancarios (banco, tipo y número de cuenta).
- **Licencia:** el dataset se publica bajo CC BY-SA 4.0 (confirmar el nombre exacto en la pestaña de metadatos de la ficha, Anexo A). Exige atribución y compartir con la misma licencia lo que se derive de los datos (sección 6.3). Revisar también los términos de uso de Colombia Compra Eficiente.
- **Trazabilidad:** registrar la fecha de consulta, porque los datos se actualizan a diario. Los enlaces de descarga de cada dataset y documento están en el Anexo A.

> **Cita sugerida (APA 7).** Colombia Compra Eficiente. (2026). *SECOP II – Contratos electrónicos* [Conjunto de datos]. Datos Abiertos Colombia. Licencia CC BY-SA 4.0. [URL del dataset, ver Anexo A]. Consultado el [fecha de descarga].

4. Componente A: asistente en la nube (RAG)

4.1 Definición

Elemento	Definición
Objetivo	Construir en la nube un pipeline de ingesta, fragmentación, vectorización y recuperación semántica sobre normativa de contratación pública, integrado con una base SQL de contratos de SECOP II, para responder preguntas en lenguaje natural con fuentes verificables.
Pregunta orientadora	¿Cómo combinar una base SQL de contratos públicos y una base vectorial serverless con normativa de contratación, de modo que un asistente recupere información con alta precisión, costo cero y baja latencia, y cite sus fuentes?

Elemento	Definición
Dataset base	SECOP II – Contratos Electrónicos (subconjunto por departamento y año).
Corpus documental	Ley 80 de 1993, Ley 1150 de 2007 y un tercer documento (fragmento del Decreto 1082 de 2015 o manual de datos abiertos del SECOP), en Markdown con metadatos.
Stack	SQLite (datos tabulares); Qdrant Cloud (colección `normativa` y, opcional, `objetos_contratos`); Gemini Embedding 2 (768 dimensiones); LangChain text splitters; Streamlit; Jupyter o Colab; GitHub.

4.2 Arquitectura

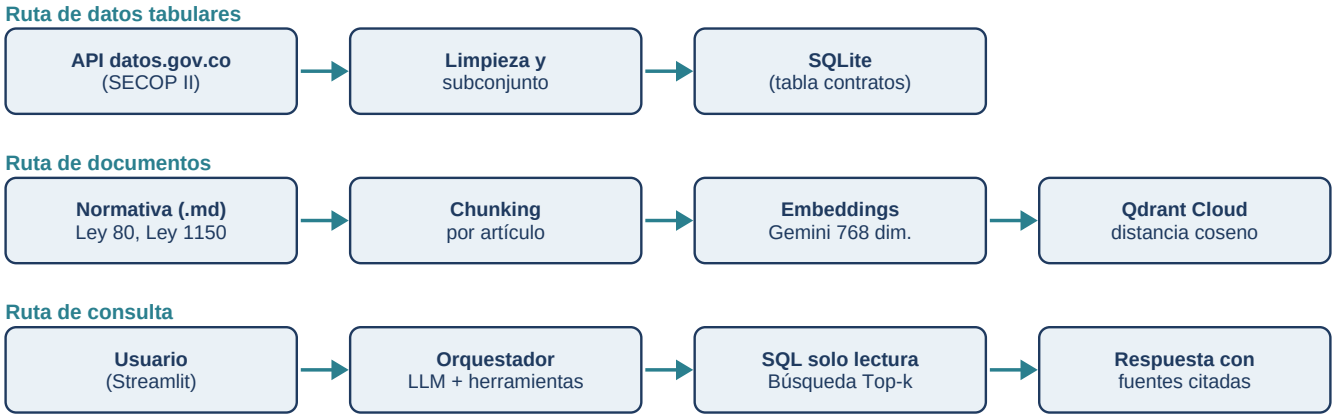

4.3 Requerimientos funcionales

ID	Requerimiento	Criterio de aceptación	Prioridad
RF-1	Aprovisionar clúster gratuito en Qdrant Cloud con colección en distancia coseno y dimensión igual a la del modelo.	La consulta de colecciones responde; las credenciales se leen solo desde `.env`.	Esencial
RF-2	Descargar el subconjunto vía API, limpiarlo y cargarlo en SQLite.	El conteo en SQLite coincide con el de la API; índices creados; fecha de consulta registrada.	Esencial
RF-3	Reunir de 2 a 3 documentos normativos con metadatos.	Cada archivo declara documento, tipo de fuente, tema y fecha.	Esencial
RF-4	Fragmentar por artículo con RecursiveCharacterTextSplitter y comparar al menos tres tamaños.	Tabla comparativa (fragmentos, longitud media, mínimo, máximo), tamaño elegido con justificación y ningún fragmento cortado a mitad de palabra.	Esencial
RF-5	Vectorizar por lotes con Gemini Embedding 2 y cargar con upsert por lotes.	Puntos en Qdrant igual al número de fragmentos; vectores guardados en disco; sin exceder la capa gratuita.	Esencial
RF-6	Función de búsqueda: vectoriza la pregunta, consulta Top-k y devuelve texto, score coseno, documento y artículo.	Resultados en tabla; filtro opcional por documento.	Esencial
RF-7	Validar con 10 a 15 preguntas: directas, parafraseadas, mixtas y sin respuesta.	Promedio, máximo y mínimo de scores; porcentaje de aciertos en top-1 y top-3; análisis de fallos.	Esencial
RF-8	Generar consultas SQL desde lenguaje natural.	Solo lectura, una sentencia SELECT, límite de filas y SQL visible al usuario.	Recomendado

ID	Requerimiento	Criterio de aceptación	Prioridad
RF-9	Interfaz de chat en Streamlit con memoria corta.	Cada respuesta muestra el SQL ejecutado y las fuentes (documento y artículo); rechaza lo que no está en las fuentes.	Recomendado
RF-10	Proteger la demo pública.	Claves solo en secretos del servidor; límite de consultas por sesión; tope de cuota en el proveedor.	Recomendado

4.4 Requerimientos no funcionales

- **Seguridad:** ninguna clave en el notebook ni en el repositorio; incluir `.env.example` sin valores.
- **Reproducibilidad:** el notebook se ejecuta de principio a fin sin errores y muestra el Top-k recuperado.
- **Costo cero:** capa gratuita de Qdrant y de la API de embeddings; verificar los límites vigentes en Google AI Studio antes de vectorizar.
- **Privacidad:** sin datos personales en la base SQL, la base vectorial, la demo ni las imágenes publicadas.
- **Latencia objetivo:** menos de 5 segundos por consulta (objetivo de diseño a medir en la validación).
- **Compatibilidad del modelo:** con `gemini-embedding-2` el tipo de tarea se indica con prefijos en el texto (`title: ... | text: ...` para documentos y `task: search result | query: ...` para consultas), no con el parámetro `task_type`. Si prefieres ese parámetro, elige un modelo que lo admita y verifícalo en la documentación.

4.5 Banco de preguntas de validación (ejemplos)

Tipo	Pregunta	Fuente esperada
Directa	¿Cuándo procede la contratación directa?	Ley 1150 de 2007 (verificar el artículo en el .md)
Parafraseada	¿En qué casos una entidad puede contratar sin licitación?	Ley 1150 de 2007
SQL	¿Cuántos contratos de prestación de servicios se firmaron en 2024 en el departamento elegido?	Tabla de contratos
SQL	¿Cuáles son los cinco proveedores con mayor valor contratado?	Tabla de contratos (solo personas jurídicas)
Mixta	¿Cuántos contratos se firmaron por contratación directa y qué dice la ley sobre esa modalidad?	Tabla de contratos y Ley 1150
Sin respuesta	¿Cuál fue el contrato más barato firmado en Francia?	El asistente debe indicar que no hay información

5. Componente B: Machine Learning clásico con Streamlit

5.1 Definición del problema

Elemento	Definición
Objetivo	Desarrollar una solución de Machine Learning clásico que, con la información disponible al firmar un contrato, estime la probabilidad de que requiera prórroga de plazo, y presentarla en una interfaz Streamlit para usuarios no técnicos.
Pregunta orientadora	¿Cómo transformar los datos abiertos de contratación pública en una estimación de riesgo de prórroga que ayude a priorizar la revisión humana y se pueda consultar desde una interfaz accesible?
Tipo de problema	Clasificación binaria supervisada.
Variable objetivo	Contrato con prórroga: el campo `dias_adicionados` (días adicionados al contrato electrónico) es mayor que cero. Las prórrogas pueden indicar problemas de planeación o de ejecución; estimarlas sirve para priorizar la revisión, no para sancionar.

Elemento	Definición
Validación previa	En el EDA, revisar el porcentaje de nulos de la variable objetivo y la proporción de contratos con prórroga. Si el campo no es confiable, usar una de las alternativas de la tabla siguiente o contrastarlo con el dataset de Adiciones (Anexo A).

Variante	Objetivo	Algoritmos clásicos	Métricas
A. Principal	Clasificar contratos con y sin prórroga	Regresión logística, Random Forest, Gradient Boosting	Precisión, recall y F1 de la clase positiva; ROC-AUC; PR-AUC
B. Alterna	Estimar el valor del contrato (escala logarítmica)	Regresión lineal regularizada, Random Forest, Gradient Boosting	MAE, RMSE y R^2
C. Alterna	Segmentar entidades o proveedores por perfil de contratación	K-Means	Silhouette, inercia y perfilado de clústeres

5.2 Variables

Grupo	Variables
Permitidas (conocidas al firmar)	`tipo_de_contrato`, `modalidad_de_contratacion`, `sector`, `rama`, `orden`, `departamento`, `es_pyme`, `es_grupo`, `habilita_pago_adelantado`, `origen_de_los_recursos`, `codigo_de_categoria_principal` (segmento UNSPSC), `valor_del_contrato` en escala logarítmica, mes y año de firma, duración planeada.
Excluidas por fuga de información	`dias_adicionados` (es el objetivo), `valor_pagado`, `valor_facturado`, `valor_pendiente_de_pago`, `estado_contrato`, `liquidaci_n` y sus fechas, `reversion`.
Excluidas por privacidad	Nombres, documentos y domicilios de personas; datos bancarios.

> **Verificar antes de modelar.** Si `valor_del_contrato` o las fechas de fin del contrato ya reflejan las adiciones y prórrogas, dejan de ser conocidas al firmar y causan fuga de información: excluirlas o recalcularlas.

5.3 Flujo metodológico

Del dato a la aplicación

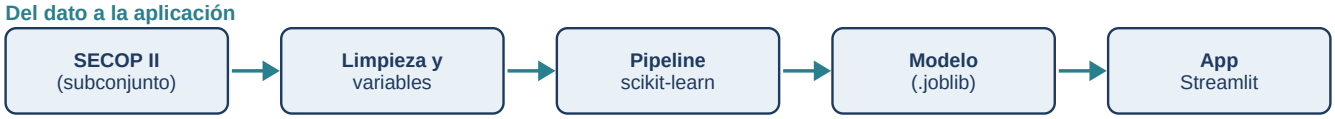

Paso	Actividades concretas en el caso
1. Exploración y EDA	Distribución de la variable objetivo; nulos por columna; contratos por modalidad, tipo y departamento; relación entre valor (logarítmico) y prórroga; revisión del desbalance de clases.
2. Limpieza y preprocesamiento	Eliminar duplicados por `id_contrato`; convertir fechas y valores; agrupar categorías poco frecuentes; imputar nulos; codificar variables categóricas; escalar las numéricas cuando el algoritmo lo requiera. Todo dentro de un Pipeline de scikit-learn.
3. Modelado clásico	Baseline (DummyClassifier), regresión logística, Random Forest y Gradient Boosting. División temporal: entrenar con los años anteriores y probar con el más reciente. Validación cruzada y búsqueda de hiperparámetros solo sobre el conjunto de entrenamiento; manejo del desbalance con pesos de clase.
4. Evaluación	Matriz de confusión; precisión, recall y F1 de la clase positiva; ROC-AUC y PR-AUC; comparación contra el baseline; importancia por permutación; análisis de errores por modalidad y departamento.
5. Despliegue	Exportar el Pipeline con joblib; aplicación Streamlit con pestañas; `requirements.txt` con versiones fijas; prueba local con `streamlit run app.py`; publicación en una plataforma de alojamiento.

5.4 Requerimientos funcionales

ID	Requerimiento	Criterio de aceptación	Prioridad
RF-ML1	Obtener un dataset reproducible.	Un script o celda regenera el subconjunto y registra la fecha de consulta.	Esencial
RF-ML2	Preprocesar sin fuga de información.	Todas las transformaciones se ajustan solo con el conjunto de entrenamiento.	Esencial
RF-ML3	Comparar un baseline y al menos tres algoritmos clásicos.	Tabla comparativa y justificación del modelo elegido.	Esencial
RF-ML4	Evaluar en el conjunto de prueba temporal.	Métricas, matriz de confusión e interpretación en celdas de texto.	Esencial
RF-ML5	Construir la interfaz con cuatro pestañas.	Contexto (fuente y fecha de corte); Exploración (filtros por departamento, modalidad y año con gráficos); Predicción (formulario con validación que muestra probabilidad, nivel de riesgo y factores principales); Métricas (tabla, matriz de confusión y comparación de modelos).	Esencial
RF-ML6	Integrar el modelo entrenado en la aplicación.	La app carga el artefacto, no reentrena; la predicción coincide con la del notebook para el mismo registro.	Esencial
RF-ML7	Comunicar el uso responsable.	Aviso visible en la app, el README y el artículo; enlace al proceso original del contrato.	Esencial
RF-ML8	Documentar el modelo con una ficha (model card).	Datos usados, métricas, límites conocidos y usos no recomendados.	Recomendado

5.5 Requerimientos no funcionales y criterios de éxito

- **Reproducibilidad:** semilla aleatoria fija y versiones de librerías fijadas en `requirements.txt`.
- **Interpretabilidad:** algoritmos clásicos con importancia de variables explicada en lenguaje claro.
- **Modularidad:** `app.py` más módulos auxiliares para carga del modelo, validación de entradas y gráficos.
- **Desempeño:** predicción individual en menos de 2 segundos (objetivo de diseño).
- **Privacidad:** la app y el modelo no usan ni muestran datos personales.

> **Criterios de éxito.** El modelo supera al baseline en F1 de la clase positiva y en PR-AUC sobre el conjunto de prueba temporal; los resultados se interpretan con sus límites; la aplicación reproduce la predicción del notebook.

6. Publicación: repositorio, demo, blog y LinkedIn

6.1 Entregables publicables

Entregable	Contenido	Dónde
Repositorio	README (problema, arquitectura, cómo ejecutarlo, resultados y límites), notebooks, app, `requirements.txt`, `.env.example`, licencia del código y aviso de licencia CC BY-SA 4.0 para los datos derivados. Sin claves ni datos personales.	GitHub público
Demo pública	Aplicación Streamlit desplegada, más un video o GIF de 60 a 90 segundos como respaldo si la demo no está disponible.	Plataforma de alojamiento gratuita (Streamlit Community Cloud o Hugging Face Spaces; verificar límites vigentes)
Artículo de blog	Problema; datos y fuentes; arquitectura; decisiones técnicas y errores corregidos; resultados con métricas y ejemplos; límites y uso responsable; cómo replicarlo.	Blog personal

Entregable	Contenido	Dónde
Publicación en LinkedIn	Texto breve (unas 150 a 250 palabras): el problema, tres aprendizajes concretos, una imagen del diagrama o un GIF de la demo y enlaces al artículo y al repositorio.	LinkedIn

Si el proyecto es extenso, publicarlo como dos piezas (una por componente) da más contenido y permite mostrar el avance por etapas.

6.2 Riesgos y buenas prácticas antes de publicar

Riesgo	Mitigación
Claves expuestas en el repositorio	Variables de entorno y secretos del servidor; revisar el historial de Git antes de hacerlo público; regenerar cualquier clave que se haya subido.
Abuso de la cuota o costo de la demo pública	Límite de consultas por sesión, caché de respuestas, tope de cuota en el proveedor, o demo con ejemplos pregrabados.
SQL peligroso o instrucciones ocultas en textos de contratos	Base en modo solo lectura, una sola sentencia SELECT y límite de filas. Tratar el texto de los contratos como datos, nunca como instrucciones.
Daño reputacional al señalar entidades o proveedores	Mostrar agregados y patrones, usar lenguaje neutral, no calificar de corrupción, incluir el aviso de uso responsable y el enlace al proceso original.
Datos personales de contratistas	El campo `proveedor_adjudicado` puede corresponder a una persona natural. En la demo mostrar solo personas jurídicas (por ejemplo, filtrando por `tipodocproveedor`; verificar los valores reales) o agregar sin nombres.
Licencia y atribución	Cumplir las condiciones de CC BY-SA 4.0 (sección 6.3): atribución, indicación de modificaciones, compartir los datos derivados con la misma licencia y aviso de no afiliación a Colombia Compra Eficiente.
Datos desactualizados	Mostrar la fecha de corte en la interfaz y en el artículo.
Exagerar los resultados del modelo	Reportar métricas frente al baseline, explicar los límites y no presentar la probabilidad como veredicto.

6.3 Licencia de los datos: CC BY-SA 4.0

El dataset principal se publica bajo la licencia Creative Commons Atribución-CompartirIgual 4.0 Internacional (CC BY-SA 4.0), según la consulta hecha por el autor del proyecto. Confirmar el nombre exacto de la licencia y la forma de atribución solicitada en la pestaña de metadatos de la ficha (Anexo A). La tabla resume las condiciones y lo que implican aquí; no es asesoría jurídica.

Condición de la licencia	Qué implica en el proyecto
Atribución	Al compartir los datos, incluso modificados, identificar al titular, enlazar al dataset, indicar la licencia con enlace a su texto y conservar los avisos que provea el licenciante. Incluir la atribución en el README, la app y el artículo.
Indicar las modificaciones	Declarar que los datos se filtraron, limpiaron y transformaron (subconjunto, conversión de tipos, columnas derivadas).
CompartirIgual	El material adaptado que se comparta debe licenciarse con CC BY-SA 4.0 (misma versión o posterior) o con una licencia compatible. Un subconjunto limpio publicado como CSV o SQLite es material adaptado.
Derechos sobre bases de datos	La licencia cubre los derechos sobre bases de datos. Una base propia que incluya todo o una parte sustancial del contenido es material adaptado, aunque sus datos individuales no cambien.
Sin restricciones adicionales	No imponer condiciones extra ni medidas técnicas que impidan a otras personas ejercer los derechos de la licencia sobre los datos publicados.

Condición de la licencia	Qué implica en el proyecto
Sin aval	No sugerir que Colombia Compra Eficiente respalda o patrocina el proyecto. Mantener el aviso de no afiliación.
Privacidad	La licencia no cubre los derechos de privacidad ni de personalidad. Los datos personales siguen sujetos a la normativa colombiana (por ejemplo, la Ley 1581 de 2012). Mantener la exclusión de datos personales.
Sin garantías e incumplimiento	Los datos se ofrecen tal cual. Si se incumple una condición, los derechos de uso terminan automáticamente y se restablecen si se corrige dentro de los 30 días siguientes a detectarla: corregir de inmediato.

Decisiones sugeridas

- **Código:** licencia propia (por ejemplo, MIT) en el archivo LICENSE.
- **Datos derivados** (CSV o SQLite del subconjunto): CC BY-SA 4.0, con un archivo de aviso que incluya la atribución.
- **Alternativa conservadora:** no publicar el subconjunto; publicar solo el script que lo descarga y los resultados agregados, siempre con atribución.
- **Modelo entrenado:** la licencia no aclara si un modelo entrenado con estos datos es material adaptado. Citar la fuente en la ficha del modelo y consultar una fuente jurídica antes de licenciarlo con condiciones distintas.

Plantilla de atribución (README, app y artículo; si la ficha del dataset pide otra forma, usar esa):

```
Datos: «SECOP II – Contratos Electrónicos», Colombia Compra Eficiente (Agencia Nacional de Contratación Pública), Portal Nacional de Datos Abiertos. https://www.datos.gov.co/Estad-sticas-Nacionales/SECOP-II-Contratos-Electr-nicos/jbjy-vk9h. Licencia: CC BY-SA 4.0, https://creativecommons.org/licenses/by-sa/4.0/. Consultado el [fecha]. Modificaciones: se filtró por [departamento y años], se limpió y se agregaron columnas derivadas. Este subconjunto derivado se comparte bajo CC BY-SA 4.0. Este proyecto no está afiliado ni respaldado por Colombia Compra Eficiente.
```

7. Plan de trabajo sugerido

Etapa	Resultado esperado
1. Datos (compartida)	Subconjunto descargado, limpiado y cargado en SQLite, con diccionario de columnas y fecha de consulta.
2. Componente A	Corpus en Markdown, chunking comparado, embeddings por lotes, colección en Qdrant, búsqueda y validación con 10 a 15 preguntas.
3. Componente B	EDA, preprocesamiento sin fuga, comparación de modelos y evaluación en el conjunto de prueba temporal.
4. Aplicación	App Streamlit con asistente y predicción, probada de principio a fin.
5. Repositorio y demo	README, ficha del modelo, revisión de claves y datos personales, y demo desplegada.
6. Blog y LinkedIn	Artículo publicado y publicación en LinkedIn con imagen y enlaces funcionales.

Anexo A. Enlaces de descarga y consulta

Estado de cada enlace: **Verificado** significa que la dirección apareció en una página o resultado oficial consultado el 28 de octubre de 2026. **Por confirmar** significa que proviene de una fuente de terceros o del patrón estándar de la plataforma. La ficha del dataset principal en datos.gov.co se abrió y confirma el identificador, pero su contenido (licencia, columnas) se carga con JavaScript y no pudo leerse desde este entorno (la licencia CC BY-SA 4.0 proviene de la consulta hecha por el autor del proyecto); los enlaces de API y CSV no pudieron probarse.

Recurso	Qué contiene y uso	Enlace	Estado
A. Datos tabulares			
SECOP II – Contratos Electrónicos (ficha del dataset principal)	Contratos con 87 columnas. Fuente de la base SQL y del modelo. La pestaña de metadatos muestra licencia, fuente y frecuencia de actualización.	Página: https://www.datos.gov.co/Estad-sticas-Nacionales/SECOP-II-Contratos-Electr-nicos/jbjy-vk9h Metadatos: https://www.datos.gov.co/Estad-sticas-Nacionales/SECOP-II-Contratos-Electr-nicos/jbjy-vk9h/about_data	**Verificado**
SECOP II – Contratos Electrónicos (descarga por API)	Mismo dataset, descargable por API en JSON o CSV con filtros.	API JSON: https://www.datos.gov.co/resource/jbjy-vk9h.json CSV: https://www.datos.gov.co/resource/jbjy-vk9h.csv	**Por confirmar**
SECOP II – Adiciones a contratos	Adiciones registradas en SECOP II. Opcional: contrastar la variable objetivo; revisar sus columnas.	Página: https://www.datos.gov.co/d/cb9c-h8sn API JSON: https://www.datos.gov.co/resource/cb9c-h8sn.json	**Por confirmar**
SECOP II – Procesos de Contratación	Procesos de compra (licitaciones, convocatorias). Opcional.	Página: https://www.datos.gov.co/d/p6dx-8zbt	**Por confirmar**
SECOP II – Ejecución Contratos	Avance estimado y real de la ejecución. Opcional. Un repositorio de terceros reporta el identificador mfmm-jqmq.	Página CCE: https://www.colombiacompra.gov.co/archivos/conjunto-datos-abier/ejecucion-contratos	**Verificado**
B. Documentación y portales de datos			
Portal de datos abiertos de Colombia Compra Eficiente	Punto de entrada a los conjuntos de datos abiertos del SECOP.	https://www.colombiacompra.gov.co/transparencia/datos-abiertos	**Verificado**
Listado de conjuntos de datos SECOP II	Descripción y enlace de cada conjunto de SECOP II.	https://www.colombiacompra.gov.co/archivos/app-datos-abiertos/secop-ii	**Verificado**
Diccionario de datos y ficha técnica	Descripción de las columnas, cobertura y marco normativo.	https://www.colombiacompra.gov.co/wp-content/uploads/2026/01/Diccionario_de_Datos_RegistrosAdministrativos-1.pdf	**Verificado**
Manual de datos abiertos del SECOP	Guía para consultar y procesar los datos del portal.	https://colombiacompra.gov.co/wp-content/uploads/2024/09/manual_de_datos_abiertos_actualizado.pdf	**Verificado**
Términos y condiciones de Colombia Compra Eficiente	Revisar antes de publicar el proyecto.	https://www.colombiacompra.gov.co/terminos-condiciones	**Verificado**
Licencia CC BY-SA 4.0 (texto legal)	Condiciones de atribución y CompartirIgual que aplican a los datos y a sus adaptaciones.	https://creativecommons.org/licenses/by-sa/4.0/	**Verificado**
C. Normativa para el corpus			
Ley 80 de 1993	Estatuto General de Contratación. La Ley 2160 de 2021 la modificó: usar la versión con notas de vigencia.	http://www.secretariasenado.gov.co/senado/basedoc/ley_0080_1993.html	**Por confirmar**
Ley 1150 de 2007	Eficiencia y transparencia en la contratación; modalidades de selección.	http://www.secretariasenado.gov.co/senado/basedoc/ley_1150_2007.html	**Por confirmar**
Decreto 1082 de 2015	Decreto Único Reglamentario del sector de Planeación Nacional. Usar solo el título de contratación estatal.	https://www.funcionpublica.gov.co/eva/gestornormativo/norma.php?i=77653	**Verificado**
Ley 1712 de 2014	Transparencia y acceso a la información pública. Opcional.	http://www.secretariasenado.gov.co/senado/basedoc/ley_1712_2014.html	**Por confirmar**

Recurso	Qué contiene y uso	Enlace	Estado
Circular Externa Única de Colombia Compra Eficiente	Reglas de uso del SECOP; su índice incluye datos abiertos y prórrogas y adiciones durante la Ley de Garantías. Opcional como tercer documento.	https://www.colombiacompra.gov.co/normativa-y-relatoria/circular-unica-externa	**Verificado**
Guías y manuales de Colombia Compra Eficiente	Manuales y guías oficiales del SECOP.	https://www.colombiacompra.gov.co/normativa-y-relatoria/guias-y-manuales	**Verificado**
D. Documentación técnica			
Gemini API – Embeddings	Modelos, dimensiones y uso de prefijos para documentos y consultas.	https://ai.google.dev/gemini-api/docs/embeddings	**Verificado**
Qdrant – Documentación	Colecciones, distancia coseno, filtros y carga por lotes.	https://qdrant.tech/documentation/	**Por confirmar**
Streamlit – Documentación	Componentes de chat, caché y despliegue.	https://docs.streamlit.io	**Por confirmar**
Socrata (SODA) – Consultas	Parámetros $select, $where, $limit, $offset y $order de la API.	https://dev.socrata.com/docs/queries/	**Por confirmar**
SECOP-MCP (repositorio de terceros)	Ejemplo de consultas a SECOP II vía Socrata; útil como referencia de columnas.	https://github.com/amgallego8/SECOP-MCP	**Verificado**

A.2 Cómo descargar un subconjunto

- **Desde el portal:** abrir la página del dataset, filtrar por departamento y fecha de firma y exportar en CSV.
- **Por API (recomendado, reproducible):** los ejemplos siguen el patrón estándar de Socrata. Probar primero con `$limit=5` para confirmar los nombres y los valores reales de las columnas.
- **Descarga completa:** no se recomienda. El dataset tiene millones de filas y no es necesario para el proyecto.

```
Muestra: https://www.datos.gov.co/resource/jbjy-vk9h.csv?$limit=5
Conteo: https://www.datos.gov.co/resource/jbjy-vk9h.json?$select=count(*)
Subconjunto: https://www.datos.gov.co/resource/jbjy-vk9h.csv?$where=departamento='Valle del Cauca' AND fecha_de_firma>='2024-01-01T00:00:00'&$order=id_contrato&$limit=50000&$offset=0
```

En código, pasar los parámetros con el argumento `params` de la librería requests para que se codifiquen los espacios y las comillas, y paginar con `$offset`. Un App Token de Socrata (opcional) amplía el límite de peticiones.

8. Referencias (APA 7)

Colombia Compra Eficiente. (2025). *Diccionario de datos y ficha técnica – Registros administrativos* (Versión 1.0). Agencia Nacional de Contratación Pública. https://www.colombiacompra.gov.co/wp-content/uploads/2026/01/Diccionario_de_Datos_RegistrosAdministrativos-1.pdf

Colombia Compra Eficiente. (2026). *SECOP II – Contratos electrónicos* [Conjunto de datos]. Datos Abiertos Colombia. https://www.datos.gov.co/Estad-sticas-Nacionales/SECOP-II-Contratos-Electr-nicos/jbjy-vk9h [completar con la fecha de consulta]

Congreso de la República de Colombia. (1993). *Ley 80 de 1993, por la cual se expide el Estatuto General de Contratación de la Administración Pública*. http://www.secretariasenado.gov.co/senado/basedoc/ley_0080_1993.html

Congreso de la República de Colombia. (2007). *Ley 1150 de 2007, por medio de la cual se introducen medidas para la eficiencia y la transparencia en la Ley 80 de 1993*. http://www.secretariasenado.gov.co/senado/basedoc/ley_1150_2007.html

Creative Commons. (s. f.). *Attribution-ShareAlike 4.0 International (CC BY-SA 4.0)*. https://creativecommons.org/licenses/by-sa/4.0/

Google. (s. f.). *Embeddings*. Gemini API. https://ai.google.dev/gemini-api/docs/embeddings

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems, 33*, 9459–9474. https://arxiv.org/abs/2005.11401

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

Presidencia de la República de Colombia. (2015). *Decreto 1082 de 2015, Decreto Único Reglamentario del Sector Administrativo de Planeación Nacional*. https://www.funcionpublica.gov.co/eva/gestornormativo/norma.php?i=77653

Qdrant Solutions GmbH. (2024). *Qdrant documentation: Vector search engine & cloud database*. https://qdrant.tech/documentation/

Streamlit Inc. (s. f.). *Streamlit documentation*. https://docs.streamlit.io